




Машинное обучение

Лекция 2. Линейные модели. Градиентный спуск

(11.02.2023)



Общие сведения

План



1. Линейная модель регрессии
2. Как линейные модели обучаются?
3. Линейная модель классификации


Что это такое?



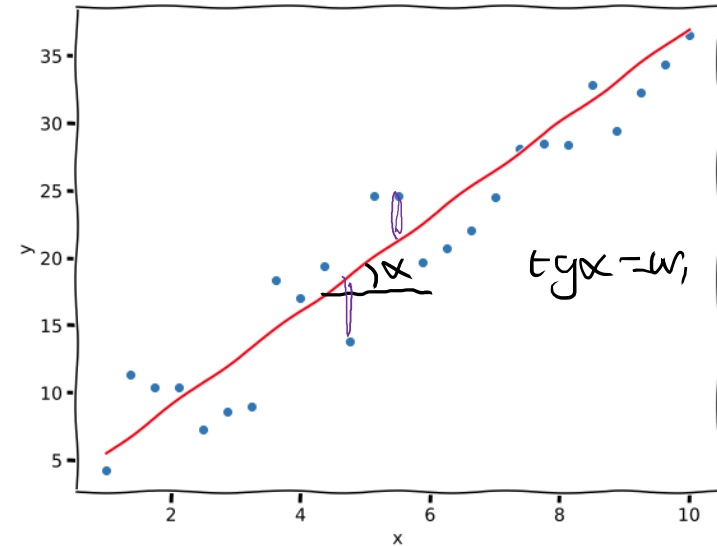

x — баллы за экзамен по английскому 1

y — баллы за экзамен по английскому 2

x	y
1	5
3	11
9	35
10	33



Что это такое?



А какая модель нам нужна?



$$\checkmark MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \rightarrow \min$$



$$\checkmark MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \rightarrow \min$$

$$y = w_0 + w_1 x + \varepsilon$$

$$\hat{y} = w_0 + w_1 x$$

$$y - \hat{y} = \varepsilon \rightarrow \min$$

$$\text{custom_MSE} = \begin{cases} \varepsilon > 0: \varepsilon^2 \cdot 0.5 \\ \varepsilon \leq 0: \varepsilon^2 \cdot 1.0 \end{cases}$$



~~Интерпретация коэффициентов~~

Стандартизация

$$x_i = \frac{x_i - \bar{x}}{G(x)} \rightarrow N(0,1)$$

1) KNN?

2) $y = w_0 + w_1 \cdot \text{рост} + w_2 \cdot \text{возраст}$

y - вес, кг

$$kg = w_0 + w_1 \cdot \frac{kg}{cm} + w_2 \cdot \frac{kg}{лет}$$

$$y \sim 10^3$$

$$x_1 \sim 10^5$$


$$w_1 \sim 10^{-2}$$

$$x_2 \sim 10^1$$

$$w_2 \sim 10^2$$

Зачем нужны линейные модели?

- 1. Предсказание интересующей нас величины
- 2. Оценка влияния различных факторов на нашу целевую переменную
- 3. Линейные модели очень легко использовать и интерпретировать
- 4. Линейные модели могут восстанавливать даже **нелинейные зависимости**




А если у нас много независимых переменных?



$$y = w_0 + w_1 x + w_2 z + \dots + w_n t + \epsilon$$

площадь	число комнат	школа близко	цена квартиры
50	2	нет	5000
1000	7	да	11000
30	1	нет	3500
100	4	нет	33333

Множественная линейная регрессия дает нам плоскость



Производные



$$\frac{dy}{dx} = \frac{y(x_0 + \Delta x) - y(x_0)}{\Delta x}$$

$$1) \quad x_1 + \frac{dy}{dx}(x_1)$$



y - убыв.

$$2) \quad x_0 + \frac{dy}{dx}(x_0)$$

y - убыв



$$x_1 - \frac{dy}{dx}(x_1) \Rightarrow y - \text{увелич}$$

$$\min/\max = \frac{x_i \leq \max}{x_{\max} - x_{\min}}$$

$y = f(x)$	$\frac{dy}{dx} = f'(x)$
k , any constant	0
x	1
x^2	$2x$
x^3	$3x^2$
x^n , any constant n	nx^{n-1}
e^x	e^x
e^{kx}	ke^{kx}
$\ln x = \log_e x$	$\frac{1}{x}$
$\sin x$	$\cos x$
$\sin kx$	$k \cos kx$
$\cos x$	$-\sin x$
$\cos kx$	$-k \sin kx$

Производные

$(0, 0, \frac{\pi}{2})$ - ответ

$$\varphi(x, y, z) = x^2 + 3y^2 - \sin z$$

$$\frac{\partial \varphi}{\partial x} = 2x$$

$$\frac{\partial \varphi}{\partial y} = 6y$$

$$\frac{\partial \varphi}{\partial z} = -\cos z$$


$$\begin{pmatrix} 2x \\ 6y \\ -\cos z \end{pmatrix} \text{ - градиент}$$

$$\varphi = \nabla_{xyz} \varphi$$

Производные (градиент)



- указывает в напр. наиб. роста ф-ции ✓
- Антиградиент указ. в напр. ^{наим.} убав.



$$\begin{pmatrix} x \\ b \\ z \end{pmatrix} - \begin{pmatrix} \frac{\partial y}{\partial x} \\ \frac{\partial y}{\partial b} \\ \frac{\partial y}{\partial z} \end{pmatrix} = \begin{pmatrix} x - \frac{\partial y}{\partial x} \\ b - \frac{\partial y}{\partial b} \\ z - \frac{\partial y}{\partial z} \end{pmatrix}$$

$y_0 \rightarrow y_1$

Производные



Как оценивать коэффициенты модели?

1) X , y , w
 $n \times 3$, $n \times 1$, 4×1

2) $y = w_0 \cdot 1 + w_1 x_1 + \dots + w_3 x_3$

3) $\begin{bmatrix} 1 & x_1 & x_2 & x_3 \\ \vdots & & & \end{bmatrix}$

4) $y = X \cdot w$
 $n \times 1$, $n \times 4$, 4×1

5) $= 1 \cdot w_0 + x_1 w_1 + \dots + x_3 w_3 = y$

$\begin{bmatrix} 1 & x_1 & x_2 & x_3 \end{bmatrix} \begin{pmatrix} w_0 \\ w_1 \\ w_2 \\ w_3 \end{pmatrix} = \begin{pmatrix} y \end{pmatrix}$

X w y

$n \times 4$
 X
 $n \times 4$
 bias trick

Как оценивать коэффициенты модели?

1)
$$MSE = \frac{1}{N} (y - Xw)^2 = \frac{1}{N} (y - Xw)^T (y - Xw)$$

Matrix: X (n x n), w (n x 1), y (n x 1)

функция потерь
Loss-функция
↓
min

2)
$$\nabla_w MSE = \left[\frac{1}{N} \cdot 2 \cdot X^T (y - Xw) \right] = \frac{2}{N} \cdot X^T (Xw - y)$$

Dimensions: 4×1 , $4 \times n$, $n \times 1$, $4 \times n$, $n \times 4 - n \times 1$, $1 \times n$, $n \times 1$

$4 \times 1 \sim w$

$() \cdot () \rightarrow 1$

$$w_{(i+1)} = w_{(i)} - \eta \nabla MSE(w_i)$$

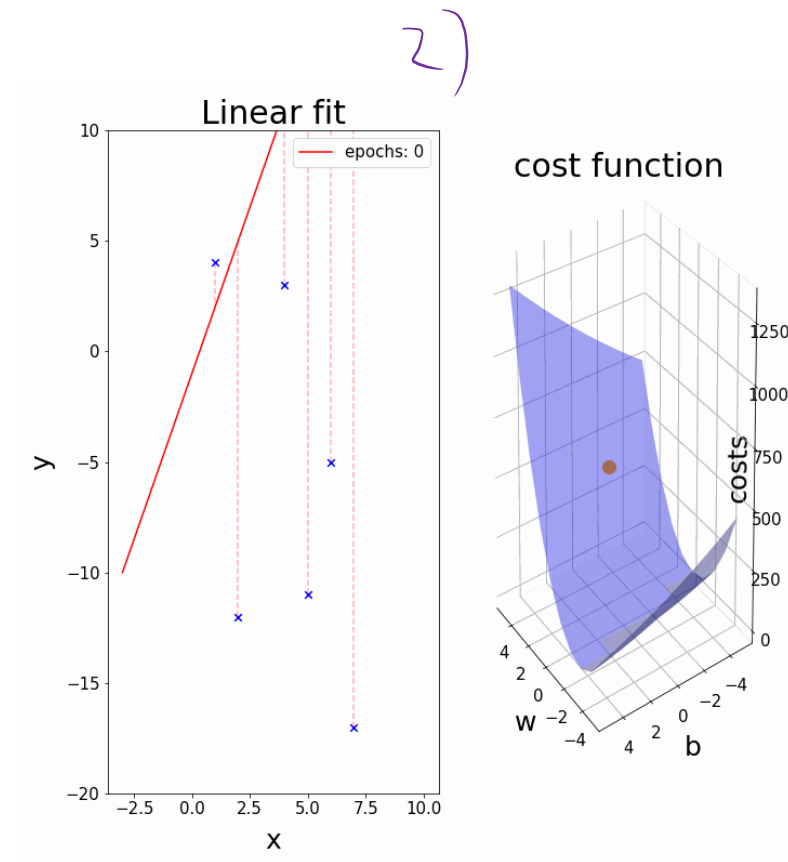

η - learning rate

$\eta: [0.001, 0.01]$



$$X @ w$$

Градиентный спуск



Формулы

$$y = w_0 + w_1 x + \epsilon$$

$$y = Xw$$

$$\frac{dLoss}{dw} = \nabla Loss = 2 \underbrace{X^T}_{\sim} (Xw - y)$$

$$Loss = \frac{1}{N} (y - Xw)^T (y - Xw)$$

✓ OLS, MARK

$$w = (X^T X)^{-1} X^T y$$

Градиентный спуск



$$Loss = \frac{1}{N} (y - Xw)^T (y - Xw) \quad \frac{dLoss}{dw} = \nabla Loss = \frac{2}{N} X^T (Xw - y)$$

```
w = np.random.randn(m + 1)
Пока grad(Loss) != 0:
    w -= η * grad(Loss)
```

Отдых -> логистическая регрессия

Связь событий и признаков



В зависимости от предикторов события могут происходить чаще или реже – логика, совпадающая с логикой связи количественной переменной отклика с набором предикторов.

Например, по мере роста температуры воздуха летом чаще будут встречаться люди в шортах: событие “встретился человек в шортах” положительно связано с температурой воздуха.


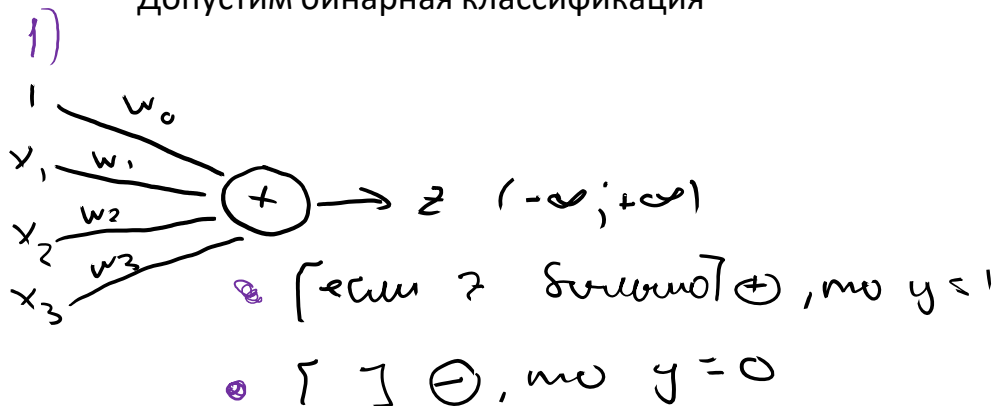
Событие “проведение исследования” явно связана с предиктором “объем полученного финансирования”, однако эта связь может быть совсем непростой.




А что если хотим классификацию?

 $y = \{0, 1\}$

Допустим бинарная классификация



Отношение шансов



Шансы (odds) часто представляют в виде отношения шансов (odds ratio)

Если отношение шансов > 1 , то вероятность наступления события выше, чем вероятность того, что оно не произойдет.

Если отношение шансов < 1 , то наоборот.

Если можно оценить вероятность положительного события, то отношение шансов выглядит так:

$$odds = \frac{\pi}{1-\pi} \quad \text{— вероятность}$$

Отношение шансов варьируется от 0 до $+\infty$.


Попробуем сами

$$Z \in (-\infty; +\infty)$$

1) p_i : [вер. того, что] $y_i = 1$
 $1 - p_i$: [] $y_i = 0$

2) $\frac{p_i}{1 - p_i} : \{0; +\infty\}$

3) $\log\left(\frac{p_i}{1 - p_i}\right) : (-\infty; +\infty)$



Логиты



Отношение шансов можно преобразовать в логиты(logit):

$$\ln(odds) = \ln\left(\frac{\pi}{1 - \pi}\right)$$

- Значения логитов – это трансформированные оценки вероятности события.
- Логиты варьируют от $-\infty$ до $+\infty$.
- Логиты симметричны относительно 0, т.е. $\ln(1)$.
- Для построения моделей в качестве зависимой переменной удобнее брать логиты.

Считаем вероятность


$$\ln\left(\frac{p_i}{1-p_i}\right) = Xw \quad | \quad \exp$$

$$\frac{p_i}{1-p_i} = e^{Xw}$$


$$p_i = e^{Xw} - p_i e^{Xw}$$

$$p_i(1 + e^{Xw}) = e^{Xw}$$

$$p_i = \frac{e^{Xw}}{1 + e^{Xw}} = \frac{1}{e^{-Xw} + 1} = G(Xw)$$



Как такое учить? BCE Loss


$$BCE = \frac{1}{N} \sum_{i=1}^N - [y_i \ln p_i + (1 - y_i) \cdot \ln(1 - p_i)]$$

$y_i = \{0, 1\}$


$$p_i \in [0, 1] \quad p_i = \sigma(x; w)$$

1) $y_i = 1; p_i = 1; BCE = 0$

2) $y_i = 1; p_i = 0; BCE = +\infty$

3) $y_i = 1; p_i = 0.5; BCE = 0.7$

Как такое учить? BCE Loss


$$\nabla_w \text{BCE} = X^T \cdot (p - y)$$
$$p = \sigma(Xw)$$


Качество классификации



Качество классификации. ROC кривая

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \text{recall}$$

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$



[рисуем свою ROC кривую](#)

Построение ROC кривой

